

# 夏令营赛题

\*课题名称：**自进化的任务求解智能体**

课题视频（非必选）：

\*课题附件

课题亮点：

当前大多数 LLM 应用只是单轮或多轮对话，缺乏自主行动与反思能力。真正有价值的智能体应当能够：**自主规划**：把一个复杂任务拆解为可执行的子步骤；**调用工具**：通过联网搜索、浏览器导航等完成每个步骤；**自我反思与进化**：对失败的尝试进行总结，修正策略，再次尝试，而不是无脑重试。

本课题要求学生实现一个具备"**尝试 → 反思 → 进化**"闭环的最小智能体系统，并在给定任务集上验证其有效性。

所需基础：

1. 大语言模型基本原理，包括但不限于：提示词工程，LLM推理框架(VLLM、Sglang)，OpenAI SDK
2. 智能体工程基本应用，包括但不限于：工具调用，沙箱部署，ReAct/Reflection框架，Harness工程，记忆系统
3. 编程语言，包括但不限于：Python，Shell
4. 基础编程能力，包括但不限于：函数封装，MCP工具，FAST API框架

研究/实践目标与预期成果：

1. 智能体搭建：基于Harness工程和ReAct架构实现一个能完成多步工具调用的最小智能体以及沙盒环境。
2. 无进化基线测试：在 2 个任务（SimpleQA和2Wiki）上测试原始智能体，记录成功率，作为基线。
3. 添加反思模块：给智能体添加"任务失败后自动反思"能力，这是进化的核心。
4. 添加记忆模块：在反思的基础上，添加记忆模块，这是进化的动力。
5. 对比评估与分析：重新在 2 个任务上测试智能体，量化"进化"带来的性能提升，评估当前智能体的进化效率。
6. 公开打榜：在huggingface的智能体测试基准上进行测试，并汇报最终成绩和排名情况。
7. 报告演示准备：准备一份最终汇报展示的ppt，包含：系统架构，核心设计说明和实验结果分析等内容

项目特色与可能的挑战：

特色 1：项目接触行业实战，你将会亲手搭建一个会自己执行，思考与记忆的智能体系统

特色 2：直击Agent前沿核心，一次掌握ReAct、Harness、Memory等智能体关键技术，接轨最热门AI 方向

特色 3：结果清晰，目标明确，从零搭建到公开打榜，用真实成绩验证你的智能体是否真正"进化"。

这是一个非常有趣但也具有挑战性的课题。

你可能会遇到的挑战有：

1. Agent 容易进入死循环，例如：不断重复搜索，工具调用错误，迟迟得不到最终答案。

需要设计合理的Harness管理和控制机制。

2. Reflection和Memory不一定有效，并不是所有反思和记忆都能带来提升。

需要思考"哪些信息才是真正有价值的反馈？"以及"记忆哪些内容才能真正帮助到之后的任务？"

3. Benchmark结果不稳定，不同Prompt或模型设置可能影响结果。

需要控制变量，重复实验，合理分析

4. 项目时间较紧

建议：优先完成最小可用系统、不追求复杂架构、优先跑通完整闭环

课题介绍（非必选）：

课题评分标准（100分制）

1. 工具搭建评分（20分）

本项目需要搭建以下两种工具：

搜索工具（0-10分），基于离线搜索工具的分数会低于在线搜索工具的分数，根据工具实现的功能种类及效率给分，满分参考标准：能够实现文搜文，图搜文功能以及搜索消耗的时间在所有队伍中排名前三。

浏览器工具（0-10分），基于本地浏览器工具的分数会低于沙盒浏览器工具的分数，根据工具实现的功能种类及效率给分，满分参考标准：能够实现访问页面，获取页面文本内容，页面点击，页面输入以及并发处理多个页面以及浏览器消耗的时间在所有队伍中排名前三。

2. 智能体搭建评分（20分）

本项目需要搭建一个基于Harness工程的ReAct智能体，该智能体能够实现多轮工具调用过程：LLM调输出tool call，工具执行结果返回，LLM分析判断是否需要进入下一轮。直到达到最大轮数或者返回最终结果。评分标准是基础智能体在SimpleQA和2Wiki两个数据集上的性能表现。

3. 反思模块评分（10分）

反思模块要求智能体在失败后能够分析失败原因，而非直接重试。评分维度：是否在失败后自动触发Reflection，是否能定位失败原因，是否能自动生成修正策略，是否能将当前任务上的反思结果运用在之后的任务中等

注：考虑到一些基模已经拥有一定的反思能力，因此该项指标更考验同学自己新增的反思模块对于先前基模性能的提升作用

#### 4. 记忆模块评分（10分）

要求智能体能将历史经验（好经验和坏经验）沉淀为长期知识，指导模型在新任务的推理中学习好的，改正错的。评分维度：是否存在短期或长期记忆，是否具备结构化存储，记忆更新手段，是否能在后续任务中有效调用，是否能减少重复错误等

#### 5. 进化效率评分（15分）

评估智能体在加入反思与记忆后是否真正实现能力提升。主要从以下四个维度展开，1.成功率提升：相较基线的成功率增长幅度。2.推理轮数优化：是否减少失败推理，失败工具调用等无效步骤。3.工具调用优化：是否减少无关工具调用等无效步骤。

#### 6. 公开打榜评分（15分）

要求在huggingface上的公开 Agent Benchmark 上测试。分数计算公式为： $\max(15 * (1 - (\text{所在队伍排名} - 1) / \text{参加本项目队伍总数}), 1)$ ，最终分数四舍五入取整数。

#### 7. 报告演示评分（10分）

PPT 结构：是否逻辑清晰

技术深度：系统设计是否新颖合理

实验完整性：是否包含充分实验与对比

展示表达：是否表达清晰

#### 8. 加分题（由评审老师酌情给分）

你是否由于基座自身的能力不足而感到苦恼，或许是时候试一试基于更大的模型采集到的数据来进行蒸馏了

必选模型：

Qwen3.5-9B (<https://huggingface.co/Qwen/Qwen3.5-9B>)

推荐工具：

本项目不强制划定工具的使用范围，推荐以下的沙盒及工具

Wikipedia 离线搜索数据 (<https://huggingface.co/datasets/XLDDD/wiki25/tree/main>)

All in One 在线搜索沙盒 (<https://github.com/agent-infra/sandbox>)

验证数据集：

SimpleQA (<https://huggingface.co/datasets/m-a-p/SimpleVQA/tree/main>)

2wiki (<https://huggingface.co/datasets/framolfese/2WikiMultihopQA/tree/main>)

打榜benchmark:

<https://huggingface.co/spaces/Tevatron/BrowseComp-Plus>

提交时请以SII-队伍名称命名，以作为审核依据